

Análisis de la señal del habla

Joaquín Sebastián Cárdenas (112311) jscardenas@fi.uba.ar

Tomás César Duer (112612) tduer@fi.uba.ar

Uma Toscan (111106) utoscan@fi.uba.ar

Marcos Joel Dias Peñaranda (111423) mdias@fi.uba.ar

Introducción

Se grabaron dos señales de audio de una voz femenina diciendo la palabra “Lapachos”, una de las muestras fue grabada diciendo la palabra de forma rápida y otra lenta. En los siguientes apartados del documento se detalla cómo se realizó un análisis completo de ambas señales mediante scripts, graficando así distintos elementos que la componen, tanto en el dominio del tiempo como en el de la frecuencia.

1. Segmentación de fonemas




Figura 1: Señal de habla lenta segmentada por tipos de fonemas.

En la Figura 1 se ubican las porciones del audio periódicas en verde (vocálicas) y no periódicas en rojo y azul (fricativas y explosivas). Los segmentos no subrayados corresponden a los momentos de silencio.

Observación: El comportamiento de la “ch” (primer segmento en rojo) es el más peculiar; estamos hablando de una señal no periódica, la cual tiene al principio un comportamiento transitorio (explosivo) para después pasar a ser un ruido no periódico vinculado más a un tipo de fonema fricativo.

2. Análisis de fonemas

2.1. Fonemas ‘a’ y ‘s’ - señal lenta y rápida




Figura 2: Fonema vocal [a] de la señal lenta.




Figura 3: Fonema fricativo [s] de la señal lenta.




Figura 4: Fonema vocal [a] de la señal rápida.




Figura 5: Fonema fricativo [s] de la señal rápida.

En las Figuras 2 y 4 se puede apreciar cómo la vocal [a] presenta una forma de onda claramente cuasi-periódica, con repeticiones regulares que reflejan la vibración de las cuerdas vocales. En contraste, la fricativa [s] (Figuras 3 y 5) muestra una señal irregular y sin ciclos definidos, semejante a ruido.

La diferencia principal entre ambos fonemas es que las vocales son cuasi-periódicas y permiten estimar una frecuencia fundamental, mientras que las fricativas son no periódicas y concentran su energía en altas frecuencias.

Al repetir el análisis con la señal rápida, la vocal [a] mostró un intervalo de duración más corto y un periodo y frecuencia fundamental ligeramente distintos; a su vez, la fricativa [s] también mostró un intervalo de duración más corto, como era de esperar.

2.2. Segmentos cuasi-periódicos - señal lenta




Figura 6: Segmento cuasi periódico de 'l' - señal lenta.




Figura 7: Segmento cuasi periódico de 'a' - señal lenta.




Figura 8: Segmento cuasi periódico de 'a' - señal lenta.




Figura 9: Segmento cuasi periódico de 'o' - señal lenta.

2.3. Segmentos cuasi-periódicos - señal rápida




Figura 10: Segmento cuasi periódico de 'l' - señal rápida.




Figura 11: Segmento cuasi periódico, primer 'a' - señal rápida.




Figura 12: Segmento cuasi periódico, segunda 'a' - señal rápida.




Figura 13: Segmento cuasi periódico de 'o' - señal rápida.

2.4. Periodos y frecuencias de los segmentos cuasi-periódicos

Para estimar el periodo de las señales cuasi-periódicas de manera gráfica, se analizó la duración de un periodo dentro de la señal (como puede verse en las Figuras 6 y 7), para luego calcular su frecuencia como $F = 1/T$.

Cuadro 1: Periodos y frecuencias de los segmentos cuasi-periódicos de la señal lenta y rápida.

Periodo y Frecuencia	Señal Lenta	Señal Rápida
Letra [L]	$T = 4 \text{ ms}$, $F = 250 \text{ Hz}$	$T = 4 \text{ ms}$, $F = 250 \text{ Hz}$
Letra [a1]	$T = 3,8 \text{ ms}$, $f = 263 \text{ Hz}$	$T = 4,5 \text{ ms}$, $f = 222 \text{ Hz}$
Letra [a2]	$T = 4 \text{ ms}$, $f = 250 \text{ Hz}$	$T = 4 \text{ ms}$, $f = 250 \text{ Hz}$
Letra [o]	$T = 5 \text{ ms}$, $f = 200 \text{ Hz}$	$T = 5 \text{ ms}$, $f = 200 \text{ Hz}$

Al ser una señal cuasi periódica, los “periodos” no son todos de una misma duración; por tanto, se podría lograr una mejor aproximación tomando mayor cantidad de muestras de periodos y promediándolos.

3. Cálculo de FFT

Para cada vocal presente en la palabra “lapachos” se extrajeron dos segmentos temporales distintos, tanto en el audio lento como en el rápido: uno abarcando varios períodos de la vocal y otro correspondiente a un único período. A cada segmento se le aplicó la Transformada Rápida de Fourier (FFT), obteniendo el espectro de magnitud. Luego se identificaron los primeros picos del espectro, acotando el rango de 0 a 2500 Hz.

Además, en las FFT de las vocálicas de varios periodos se calculó la envolvente de la señal usando el método LPC (*Linear Predictive Coding*), que es el método mas extendido y utilizado para reconocer las frecuencias de resonancia conocidas como formantes.

3.1. Gráficos de la señal lenta




Figura 14: FFT Letra [A1] - Un período - señal lenta.




Figura 15: FFT Letra [A1] - Varios períodos - señal lenta.




Figura 16: FFT Letra [A2] - Un período - señal lenta.




Figura 17: FFT Letra [A2] - Varios períodos - señal lenta.




Figura 18: FFT Letra [O] - Un período - señal lenta.




Figura 19: FFT Letra [O] - Varios períodos - señal lenta.

3.2. Gráficos de la señal rápida




Figura 20: FFT Letra [A1] - Un período - señal rápida.




Figura 21: FFT Letra [A1] - Varios períodos - señal rápida.




Figura 22: FFT Letra [A2] - Un período - señal rápida.




Figura 23: FFT Letra [A2] - Varios períodos - señal rápida.




Figura 24: FFT Letra [O] - Un período - señal rápida.




Figura 25: FFT Letra [O] - Varios períodos - señal rápida.

Vemos que las envolventes de las figuras no coinciden exactamente con la posición de los picos de la señal. El tracto vocal, que es el filtro modelado por la envolvente LPC (la línea roja), posee sus propias frecuencias de resonancia naturales denominadas formantes. Es decir, son sistemas distintos y por tanto no tienen por qué coincidir.

3.3. Tabla de resultados

Cuadro 2: Frecuencias de los primeros máximos de los espectros calculados.

Cantidad de períodos	Señal lenta		Señal rápida	
	1	Varios	1	Varios
Letra [A1]	1000 Hz	[265, 530, 795] Hz	1000 Hz	[240, 460, 700] Hz
Letra [A2]	870 Hz	[260, 520, 780] Hz	1000 Hz	[260, 520, 780] Hz
Letra [O]	500 Hz	[222, 468, 679] Hz	600 Hz	[220, 440, 660] Hz

Cuando se toman varios períodos (tamaño de ventana grande), el espectro muestra múltiples armónicos bien definidos y separados, lo que permite identificar con claridad la frecuencia fundamental F_0 y sus armónicos. Esto se debe a que al tener más muestras, la resolución de la FFT mejora debido a que el ancho de los *lóbulos* es menor y los picos quedan mejor resueltos, pudiendo determinar su posición en el espectro de frecuencias y amplitud con mayor precisión.

En cambio, al tomar un solo período, el número de muestras es mucho menor, por lo que la resolución espectral es baja y esto se traduce en la imposibilidad de identificar los armónicos, pues ocurre el fenómeno de *leakage*. En este caso, el único armónico que se puede identificar con seguridad es el de mayor energía, pero con menor precisión tanto en la amplitud como en su posición en frecuencia real. Mientras que en la señal donde se analizan varios períodos se puede identificar con claridad la frecuencia fundamental, que se aproxima a la calculada de forma gráfica en el punto dos.

Por otro lado, la comparación entre ambas velocidades de locución revela estructuras armónicas consistentes, lo que indica que la rapidez de habla no modifica significativamente la frecuencia fundamental del hablante, sino únicamente la duración de cada vocal.

4. Espectrograma de Banda Angosta

Se implementó una STFT (*Short-Time Fourier Transform*) en *Python* para obtener un espectrograma de banda angosta de la señal lenta, utilizando una ventana con una duración de aproximadamente 56 ms. Para poder observar la frecuencia fundamental y sus armónicos, además de fijar un ancho de ventana grande, que permite una resolución espectral tal que sean distinguibles los armónicos, se limitó el rango de frecuencias a graficar a un máximo de 7 kHz para cubrir el espectro relevante del habla. También se utilizó una escala de decibeles acotada entre -30 y 30 dB para resaltar las variaciones de energía.




Figura 26: Espectrograma de banda angosta de la señal lenta.

Con el gráfico obtenido, podemos observar cómo las líneas del espectrograma que representan los armónicos quedan bien definidas en los fonemas vocálicos, manteniendo una frecuencia constante durante todo el intervalo en que se pronuncian. En cambio, en los otros fonemas de la palabra, el espectro resultante es distinto:

- **Fonema explosivo (/p/):** por arriba de 2 kHz parece no haber concentración de energía y las líneas que aparecen por debajo sugieren ser más una distorsión producto de la ventana, al solaparse con la vocal anterior, que información espectral del fonema en sí. Este comportamiento puede explicarse al considerar un fonema explosivo como un sonido transitorio (pulso muy corto en el tiempo): como la ventana utilizada es larga, la resolución temporal es pobre y no es posible distinguir estos fonemas de corta duración.
- **Fonema fricativo (/s/):** Vemos que su espectro cubre casi de manera continua todo el rango de frecuencias, exceptuando el intervalo $\sim(1;3)$ kHz. Similar a lo que

se obtendría al utilizar un filtro que elimine ese rango de frecuencias aplicado sobre una fuente de ruido blanco.

- **Fonema (/ch/):** Como se mencionó en el punto uno, este fonema se puede pensar como la composición de un fonema explosivo seguido de uno fricativo. Vemos que en el gráfico esto efectivamente es así, ya que se observa una distribución de energía similar a la del fonema (/p/), seguida de una distribución similar a la observada en el fonema (/s/).

En la Tabla 3 se detallan las frecuencias estimadas de la fundamental y armónicos a partir del espectrograma de banda angosta.

Cuadro 3: Fundamental, primer y segundo armónico de los fonemas vocálicos.

Fonema	f_0 [Hz]	f_1 [Hz]	f_2 [Hz]
l	260	518	775
a1	265	530	800
a2	260	530	790
o	260 (peak)	560 (peak)	785 (peak)

En la vocal “o” la frecuencia de los armónicos desciende notablemente durante el intervalo de duración hasta llegar a $f_0 = 200$ Hz, $f_1 = 420$ Hz y $f_2 = 630$ Hz.

5. Espectrograma de Banda Ancha

Se utilizó el mismo script del punto cuatro pero con una ventana de $\sim 6,8$ ms y un rango dinámico de entre -10 y 30 dB. Con esta configuración los armónicos de los sonidos vocálicos dejan de ser distinguibles de forma separada y pasan a constituir los formantes. Además, si bien la resolución espectral se ve comprometida, se tiene una mejor resolución temporal y eso permite visualizar los transitorios de los fonemas explosivos (/p/) e inicio de (/ch/).




Figura 27: Espectrograma de banda ancha de la señal lenta.

Los formantes son las zonas donde la concentración de energía es mayor. Para los fonemas vocálicos, localizamos los formantes como la frecuencia situada en el centro de esas zonas.

Cuadro 4: Frecuencias centrales de los formantes.

Vocal	F_1 [Hz]	F_2 [Hz]
l	230	600
a1	780	1092
a2	775	1075
o	540 (peak)	861 (peak)

En la vocal “o” la frecuencia desciende notablemente durante el intervalo de duración hasta llegar a los 437 Hz el formante uno y 681 Hz el formante dos.

6. Análisis Espectral: Vocales

Nuestro interés principal del estudio se centra en las partes periódicas de la señal de audio, es decir, en las vocales. Estas regiones son las que contienen la información acústica más relevante para caracterizar la voz, ya que nos permite observar tanto la frecuencia fundamental (f_0) como las resonancias del tracto vocal (formantes).

Para profundizar en este análisis, calculamos los espectrogramas de cada vocal en particular, utilizando dos configuraciones distintas de la Transformada de Fourier de corto tiempo (STFT):

- **Espectrograma de banda angosta (ventana larga):** En los resultados obtenidos se distinguen con claridad los armónicos de la señal periódica y la frecuencia fundamental, lo que nos permite estudiar la estructura armónica de la voz y la regularidad de la vibración de las cuerdas vocales.

- **Espectrograma de banda ancha (ventana corta):** En este caso, los armónicos aparecen menos definidos, pero se identifican con mayor precisión las zonas de concentración de energía asociadas a los formantes, que son los rasgos acústicos que diferencian perceptualmente a cada vocal.




Figura 28: Espectrograma vocal a1.




Figura 29: Espectrograma de letra a2.




Figura 30: Espectrograma de letra O.

7. Modificación del Pitch de la Voz

7.1. Introducción

Se implementó el algoritmo TD-PSOLA mediante un script en Python, con el fin de modificar el pitch de la voz de la señal Lapachos lenta, multiplicando la frecuencia fundamental de los fonemas vocálicos por un factor de 0,7.

7.2. Principio de funcionamiento e implementación

En principio, se debe comprender el objetivo de esta operación. Se busca cambiar el tono de la voz, procurando no modificar la longitud de la señal de audio. La manera de lograr esto es localizando puntos donde la señal es sonora y encontrar los picos de amplitud de cada uno de estos intervalos. Una vez logrado esto, se aplica una ventana centrada en cada pico encontrado y se la desplaza temporalmente en función del pitch deseado. Teniendo todas las ventanas, se las suma para obtener la señal modificada.

Los parámetros de ajuste para obtener un resultado decente fueron: el largo de la ventana o *frame length* y el largo de salto o *hop length*. Se entiende por *hop length* a la distancia, en muestras, que “salta” la ventana al ir recorriendo la señal. Es evidente que para un *frame length* fijo, un *hop length* menor implica un mayor solapamiento y esto se traduce en mayor resolución espectral. Para el análisis de pitch y detección de segmentos periódicos, se consideró apropiado tomar un *frame length* de 46 ms y luego se fijó un *hop length* del 25% del largo de ventana (~ 12 ms), que es el valor que empíricamente nos dio mejores resultados. Para evitar la detección de segmentos periódicos sobre el ruido en los momentos de silencio, se implementó un umbral de energía mínimo para que un segmento pueda ser considerado sonoro. También se acotó el rango de búsqueda de la fundamental F_0 a entre 200 y 300 Hz, que es el rango en el que sabíamos de antemano que se encontraba la fundamental de nuestra señal gracias a los puntos anteriores. De esta forma, el algoritmo ignora los tramos insonoros y calcula las marcas de pitch únicamente donde la periodicidad glotal es clara y relevante.




Figura 31: Pitch marks sobre Lapachos lenta.




Figura 32: Pitch marks sobre tramo cuasiperiódico de Lapachos lenta.




Figura 33: Comparación de un segmento de la señal original y la modificada.




Figura 34: Espectrograma de banda angosta de la señal original.




Figura 35: Espectrograma de banda angosta de la señal modificada.

En la Figura 31 se puede observar que el algoritmo detecta correctamente los segmentos sonoros y en la Figura 32 cómo el algoritmo detecta correctamente los picos de los ciclos que conforman esos segmentos.

En la Figura 33 se muestra una comparativa de un segmento periódico de la señal original y la modificada. Del gráfico se puede estimar que, en ese segmento, el periodo aproximado T_0 de la señal original es de 4 ms ($F'_0 = 166$ Hz), mientras que el de la modificada es de 6 ms ($F_0 = 250$ Hz). De estos datos se deduce que $F'_0 = F_0 \times 0,664$. Sin embargo, a partir de los gráficos de las Figuras 34 y 35 obtenemos una estimación mejor de las frecuencias fundamentales.

Al comparar los espectrogramas de banda angosta de las Figuras 34 y 35 vemos que el de la señal modificada, respecto a la original, posee los armónicos corridos hacia las

frecuencias bajas y con una separación menor entre ellos. También vemos que por instantes los armónicos se amalgaman y esto se traduce en lo que se percibe como distorsiones en el tono o *artifacts*.

Cuadro 5: Comparación de frecuencia fundamental y armónicos de ambas señales.

vocal [a1]	f_0 [Hz]	f_1 [Hz]	f_2 [Hz]
lenta	250	500	740
modificada	170	345	515
f'_i/f_i	0,68	0,69	0,70

8. Decimación de la Señal Lenta

Se pasó de la señal Lapachos lenta a una versión acelerada al doble de su velocidad mediante un proceso de decimación. Para lograrlo, aplicamos un submuestreo con factor $M = 2$, lo que implica conservar una muestra de cada dos en el dominio temporal. Este procedimiento, sin embargo, no puede realizarse de manera directa porque al reducir la tasa de muestreo existe el riesgo de que las componentes de alta frecuencia se plieguen en el espectro, generando aliasing. Por esa razón, antes de la decimación diseñamos e implementamos mediante código un filtro antialiasing.

El filtro lo construimos con el método de ventaneo, utilizando una ventana de Hamming y un número de coeficientes suficientemente grande para garantizar una transición suave y una atenuación adecuada a las frecuencias por encima del filtro. La frecuencia de corte la fijamos en la mitad de la nueva frecuencia de Nyquist, de modo que las componentes superiores quedarán eliminadas antes del submuestreo. Una vez filtrada la señal, procedimos a la decimación, obteniendo una versión comprimida en el tiempo.




Figura 36: Espectrograma de banda ancha de Lapachos lento decimado.




Figura 37: Espectrograma de banda ancha de Lapachos rápido.

Al comparar la señal lenta decimada (Fig. 36) con la rápida original (Fig. 37), podemos ver que la decimación efectivamente logra una duración similar; sin embargo, la señal decimada presenta formantes en distintos rangos de frecuencia y diferente ancho de banda respecto a la rápida. Esto se traduce en una señal con una composición armónica muy distinta (tono diferente). Además, estos son más definidos y se resuelven mejor unos de otros, existiendo mayor separación entre cada uno. Resultando en lo que se percibe como una voz más “artificial”.

9. Interpolación de la Señal Rápida

Para realizar la interpolación de la señal rápida se hizo una expansión con ceros, duplicando el largo N del vector de la señal muestreada a $2N$. Es decir, se agrega 1 cero entre cada muestra consecutiva de la señal original. Luego, para eliminar las réplicas espectrales (producto del upsampling), se aplica un filtro pasabajos con frecuencia de corte igual a la frecuencia de Nyquist de la señal original.




Figura 38: Espectrograma de banda ancha de Lapachos rápido interpolado.




Figura 39: Espectrograma de banda ancha de Lapachos lento.

Al comparar los espectros de las señales podemos ver una interpolación efectiva debido a la duración similar de la señal interpolada (Fig. 38) con la señal lenta original (Fig. 39). Además se puede apreciar que mientras que la señal original posee una concentración de energía significativa hasta los 2000 Hz, la señal interpolada llega hasta los 1500 Hz; su espectro se concentra más en frecuencias más bajas. Esto se debe a que en la señal interpolada, al insertar ceros, estiramos el tiempo pero desplazamos proporcionalmente todas las frecuencias hacia abajo. Esto altera la posición de los formantes (las frecuencias de resonancia del tracto vocal), haciendo que la voz suene artificialmente más grave.

10. STFT: Aumentar la Velocidad de la Señal Lapachos Lenta

Para aumentar al doble la velocidad de la señal, en este punto se realizó un procesamiento sobre el espectro. Mediante un script en Python se implementó una STFT con una ventana Hann larga ($\sim 46ms$), y a la matriz de la transformada se le eliminó una de cada dos columnas. Luego, se recupera la señal temporal utilizando la iSTFT. Además, a la señal resultante se le realizó un espectrograma de banda angosta para poder visualizar los armónicos del espectro.




Figura 40: Espectrograma de banda angosta de Lapachos lenta procesada.




Figura 41: Espectrograma de banda angosta de Lapachos lenta.

Si comparamos la señal procesada (Fig. 40) con Lapachos lenta sin procesamiento (Fig. 41), vemos que si bien los armónicos están un poco menos definidos (se ven “borrosos” y son más anchos), el algoritmo produjo una señal con un espectro muy similar. Tanto en la frecuencia de la fundamental y los armónicos de cada fonema, como en sus variaciones relativas a lo largo de la duración de la pronunciación del fonema. Todo esto se traduce en una señal con una velocidad igual al doble de la original, pero que conserva el tono de la original, a diferencia de lo que ocurría en el punto 8.

11. STFT: Reducir la Velocidad de la Señal Lapachos Rápida

Para reducir a la mitad la velocidad de la señal mediante procesamiento de la STFT, se realizó la misma transformada de tiempo corto que en el punto 10. A la matriz obtenida se le realizó una interpolación lineal de las columnas originales y se recuperó la señal temporal mediante la iSTFT. Luego, se graficó el espectrograma de banda angosta de la señal resultante.




Figura 42: Espectrograma de banda angosta de Lapachos rápida procesada.




Figura 43: Espectrograma de banda angosta de Lapachos rápida.

Al comparar la señal procesada (Fig. 42) con la original (Fig. 43) vemos que los armónicos con mayor concentración de energía están situados en las mismas frecuencias. Sin embargo, el algoritmo introduce ruido entre los armónicos. Además, toda la información que está por encima de los 1000 Hz se distorsiona de manera muy notoria. Todo esto se traduce en que, si bien se conserva la estructura armónica de la señal, la voz suena un poco “robótica”. Este resultado no logramos mejorarlo modificando los parámetros de la STFT (como la ventana o el hop) antes de procesar.