

Análisis de la señal del habla

Joaquín Sebastián Cárdenas (112311) jscardenas@fi.uba.ar

Tomás César Duer (112612) tduer@fi.uba.ar

Uma Toscan (111106) utoscan@fi.uba.ar

Marcos Joel Dias Peñaranda (11423) mdias@fi.uba.ar

Introducción

Se grabaron dos señales de audio de una voz femenina diciendo la palabra “Lapachos”, una de las muestras fue grabada diciendo la palabra de forma rápida y otra lenta. En los siguientes apartados del documento se detalla cómo se realizó un análisis completo de ambas señales mediante scripts, graficando así distintos elementos que la componen, tanto en el dominio del tiempo como en el de la frecuencia.

1. Segmentación de fonemas




Figura 1: Señal de habla lenta segmentada por tipos de fonemas.

En la Figura 1 se ubican las porciones del audio periódicas en verde (vocálicas) y no periódicas en rojo y azul (fricativas y explosivas). Los segmentos no subrayados corresponden a los momentos de silencio.

Observación: El comportamiento de la “ch” (primer segmento en rojo) es el más peculiar; estamos hablando de una señal no periódica, la cual tiene al principio un comportamiento transitorio (explosivo) para después pasar a ser un ruido no periódico vinculado más a un tipo de fonema fricativo.

2. Análisis de fonemas

2.1. Fonemas 'a' y 's' - señal lenta y rápida




Figura 2: Fonema vocal [a] de la señal lenta.




Figura 3: Fonema fricativo [s] de la señal lenta.




Figura 4: Fonema vocal [a] de la señal rápida.




Figura 5: Fonema fricativo [s] de la señal rápida.

En las Figuras 2 y 4 se puede apreciar cómo la vocal [a] presenta una forma de onda claramente cuasi-periódica, con repeticiones regulares que reflejan la vibración de las cuerdas vocales. En contraste, la fricativa [s] (Figuras 3 y 5) muestra una señal irregular y sin ciclos definidos, semejante a ruido.

La diferencia principal entre ambos fonemas es que las vocales son cuasi-periódicas y permiten estimar una frecuencia fundamental, mientras que las fricativas son no periódicas y concentran su energía en altas frecuencias.

Al repetir el análisis con la señal rápida, la vocal [a] mostró un intervalo de duración más corto y un periodo y frecuencia fundamental ligeramente distintos; a su vez, la fricativa [s] también mostró un intervalo de duración más corto, como era de esperar.

2.2. Segmentos cuasi-periódicos - señal lenta




Figura 6: Segmento cuasi periódico de 'l' - señal lenta.




Figura 7: Segmento cuasi periódico de 'a' - señal lenta.




Figura 8: Segmento cuasi periódico de 'a' - señal lenta.




Figura 9: Segmento cuasi periódico de 'o' - señal lenta.

2.3. Segmentos cuasi-periódicos - señal rápida




Figura 10: Segmento cuasi periódico de 'l' - señal rápida.




Figura 11: Segmento cuasi periódico, primer 'a' - señal rápida.




Figura 12: Segmento cuasi periódico, segunda 'a' - señal rápida.




Figura 13: Segmento cuasi periódico de 'o' - señal rápida.

2.4. Periodos y frecuencias de los segmentos cuasi-periódicos

Para estimar el periodo de las señales cuasi-periódicas de manera gráfica, se analizó la duración de un periodo dentro de la señal (como puede verse en las Figuras 6 y 7), para luego calcular su frecuencia como $F = 1/T$.

Cuadro 1: Periodos y frecuencias de los segmentos cuasi-periódicos de la señal lenta y rápida.

Periodo y Frecuencia	Señal Lenta	Señal Rápida
Letra [L]	$T = 4 \text{ ms}$, $F = 250 \text{ Hz}$	$T = 4 \text{ ms}$, $F = 250 \text{ Hz}$
Letra [a1]	$T = 3,8 \text{ ms}$, $f = 263 \text{ Hz}$	$T = 4,5 \text{ ms}$, $f = 222 \text{ Hz}$
Letra [a2]	$T = 4 \text{ ms}$, $f = 250 \text{ Hz}$	$T = 4 \text{ ms}$, $f = 250 \text{ Hz}$
Letra [o]	$T = 5 \text{ ms}$, $f = 200 \text{ Hz}$	$T = 5 \text{ ms}$, $f = 200 \text{ Hz}$

Al ser una señal cuasi periódica, los “periodos” no son todos de una misma duración; por tanto, se podría lograr una mejor aproximación tomando mayor cantidad de muestras de periodos y promediándolos.

3. Cálculo de FFT

Para cada vocal presente en la palabra “lapachos” se extrajeron dos segmentos temporales distintos, tanto en el audio lento como en el rápido: uno abarcando varios periodos de la vocal y otro correspondiente a un único periodo. A cada segmento se le aplicó la Transformada Rápida de Fourier (FFT), obteniendo el espectro de magnitud. Luego se identificaron los primeros picos del espectro, acotando el rango de 0 a 2500 Hz.

3.1. Gráficos de la señal lenta




Figura 14: FFT Letra [A1] - Un periodo - señal lenta.




Figura 15: FFT Letra [A1] - Varios períodos - señal lenta.




Figura 16: FFT Letra [A2] - Un período - señal lenta.




Figura 17: FFT Letra [A2] - Varios períodos - señal lenta.




Figura 18: FFT Letra [O] - Un período - señal lenta.




Figura 19: FFT Letra [O] - Varios períodos - señal lenta.

3.2. Gráficos de la señal rápida




Figura 20: FFT Letra [A1] - Un período - señal rápida.




Figura 21: FFT Letra [A1] - Varios períodos - señal rápida.




Figura 22: FFT Letra [A2] - Un período - señal rápida.




Figura 23: FFT Letra [A2] - Varios períodos - señal rápida.




Figura 24: FFT Letra [O] - Un período - señal rápida.




Figura 25: FFT Letra [O] - Varios períodos - señal rápida.

3.3. Tabla de resultados

Cuadro 2: Frecuencias de los primeros máximos de los espectros calculados.

Cantidad de períodos	Señal lenta		Señal rápida	
	1	Varios	1	Varios
Letra [A1]	1000 Hz	[265, 530, 795] Hz	1000 Hz	[240, 460, 700] Hz
Letra [A2]	870 Hz	[260, 520, 780] Hz	1000 Hz	[260, 520, 780] Hz
Letra [O]	500 Hz	[222, 468, 679] Hz	600 Hz	[220, 440, 660] Hz

Cuando se toman varios períodos (tamaño de ventana grande), el espectro muestra múltiples armónicos bien definidos y separados, lo que permite identificar con claridad la frecuencia fundamental F_0 y sus armónicos. Esto se debe a que al tener más muestras, la resolución de la FFT mejora debido a que el ancho de los *lóbulos* es menor y los picos quedan mejor resueltos, pudiendo determinar su posición en el espectro de frecuencias y amplitud con mayor precisión.

En cambio, al tomar un solo período, el número de muestras es mucho menor, por lo que la resolución espectral es baja y esto se traduce en la imposibilidad de identificar los armónicos, pues ocurre el fenómeno de *leakage*. En este caso, el único armónico que se puede identificar con seguridad es el de mayor energía, pero con menor precisión tanto en la amplitud como en su posición en frecuencia real. Mientras que en la señal donde se analizan varios períodos se puede identificar con claridad la frecuencia fundamental, que se aproxima a la calculada de forma gráfica en el punto dos.

Por otro lado, la comparación entre ambas velocidades de locución revela estructuras armónicas consistentes, lo que indica que la rapidez de habla no modifica significativamente la frecuencia fundamental del hablante, sino únicamente la duración de cada vocal.

4. Espectrograma de Banda Angosta

Se implementó una STFT (*Short-Time Fourier Transform*) en *Python* para obtener un espectrograma de banda angosta de la señal lenta, utilizando una ventana con una duración de aproximadamente 56 ms. Para poder observar la frecuencia fundamental y sus armónicos, además de fijar un ancho de ventana grande, que permite una resolución espectral tal que sean distinguibles los armónicos, se limitó el rango de frecuencias a graficar a un máximo de 7 kHz para cubrir el espectro relevante del habla. También se utilizó una escala de decibeles acotada entre -30 y 30 dB para resaltar las variaciones de energía.




Figura 26: Espectrograma de banda angosta de la señal lenta.

Con el gráfico obtenido, podemos observar cómo las líneas del espectrograma que representan los armónicos quedan bien definidas en los fonemas vocálicos, manteniendo una frecuencia constante durante todo el intervalo en que se pronuncian. En cambio, en los otros fonemas de la palabra, el espectro resultante es distinto:

- **Fonema explosivo (/p/):** por arriba de 2 kHz parece no haber concentración de energía y las líneas que aparecen por debajo sugieren ser más una distorsión producto de la ventana, al solaparse con la vocal anterior, que información espectral del fonema en sí. Este comportamiento puede explicarse al considerar un fonema explosivo como un sonido transitorio (pulso muy corto en el tiempo): como la ventana utilizada es larga, la resolución temporal es pobre y no es posible distinguir estos fonemas de corta duración.
- **Fonema fricativo (/s/):** Vemos que su espectro cubre casi de manera continua todo el rango de frecuencias, exceptuando el intervalo $\sim(1;3)$ kHz. Similar a lo que se obtendría al utilizar un filtro que elimine ese rango de frecuencias aplicado sobre una fuente de ruido blanco.
- **Fonema (/ch/):** Como se mencionó en el punto uno, este fonema se puede pensar como la composición de un fonema explosivo seguido de uno fricativo. Vemos que

en el gráfico esto efectivamente es así, ya que se observa una distribución de energía similar a la del fonema (/p/), seguida de una distribución similar a la observada en el fonema (/s/).

En la Tabla 3 se detallan las frecuencias estimadas de la fundamental y armónicos a partir del espectrograma de banda angosta.

Cuadro 3: Fundamental, primer y segundo armónico de los fonemas vocálicos.

Fonema	f_0 [Hz]	f_1 [Hz]	f_2 [Hz]
l	260	518	775
a1	265	530	800
a2	260	530	790
o	260 (peak)	560 (peak)	785 (peak)

En la vocal “o” la frecuencia de los armónicos desciende notablemente durante el intervalo de duración hasta llegar a $f_0 = 200$ Hz, $f_1 = 420$ Hz y $f_2 = 630$ Hz.

5. Espectrograma de Banda Ancha

Se utilizó el mismo script del punto cuatro pero con una ventana de $\sim 6,8$ ms y un rango dinámico de entre -10 y 30 dB. Con esta configuración los armónicos de los sonidos vocálicos dejan de ser distinguibles de forma separada y pasan a constituir los formantes. Además, si bien la resolución espectral se ve comprometida, se tiene una mejor resolución temporal y eso permite visualizar los transitorios de los fonemas explosivos (/p/) e inicio de (/ch/).




Figura 27: Espectrograma de banda ancha de la señal lenta.

Los formantes son las zonas donde la concentración de energía es mayor. Para los fonemas vocálicos, localizamos los formantes como la frecuencia situada en el centro de esas zonas.

Cuadro 4: Frecuencias centrales de los formantes.

Vocal	F_1 [Hz]	F_2 [Hz]
l	230	600
a1	780	1092
a2	775	1075
o	540 (peak)	861 (peak)

En la vocal “o” la frecuencia desciende notablemente durante el intervalo de duración hasta llegar a los 437 Hz el formante uno y 681 Hz el formante dos.

6. Análisis Espectral: Vocales

Nuestro interés principal del estudio se centra en las partes periódicas de la señal de audio, es decir, en las vocales. Estas regiones son las que contienen la información acústica más relevante para caracterizar la voz, ya que nos permite observar tanto la frecuencia fundamental (f_0) como las resonancias del tracto vocal (formantes).

Para profundizar en este análisis, calculamos los espectrogramas de cada vocal en particular, utilizando dos configuraciones distintas de la Transformada de Fourier de corto tiempo (STFT):

- **Espectrograma de banda angosta (ventana larga):** En los resultados obtenidos se distinguen con claridad los armónicos de la señal periódica y la frecuencia fundamental, lo que nos permite estudiar la estructura armónica de la voz y la regularidad de la vibración de las cuerdas vocales.
- **Espectrograma de banda ancha (ventana corta):** En este caso, los armónicos aparecen menos definidos, pero se identifican con mayor precisión las zonas de concentración de energía asociadas a los formantes, que son los rasgos acústicos que diferencian perceptualmente a cada vocal.




Figura 28: Espectrograma vocal a1.




Figura 29: Espectrograma de letra a2.




Figura 30: Espectrograma de letra O.

7. Modificación del Pitch de la Voz

En principio, se debe comprender el objetivo de esta operación. Se busca cambiar el tono de la voz, procurando no modificar la longitud de la señal de audio. La manera de lograr esto es localizando puntos donde la señal es periódica y encontrar los picos de cada uno de estos intervalos. Una vez logrado esto, se aplica una ventana centrada en cada pico encontrado y se la desplaza temporalmente. Teniendo todas las ventanas, se las suma para obtener la señal modificada. Los parámetros que fueron vitales para que la aplicación de este algoritmo fuera efectiva fueron el largo de la ventana (*frame length*) y el *hop length*.

Se entiende por *hop length* el espacio, en muestras, aplicado entre ventana y ventana de análisis. Es evidente que si el largo de la ventana es mayor al del *hop length*, habrá solapamiento. Esto es útil y necesario para este análisis ya que nos provee de una mejor resolución temporal. Para el análisis de pitch se consideró apropiado tomar un largo de ventana de 2048 muestras y un *hop length* de 80 muestras al tratarse de un audio corto, ya que si el audio fuera más largo lo mejor sería encontrar una diferencia un poco menor entre estos valores, ya que supondría un mayor costo computacional. De esta manera se lograría un solapamiento muy denso que asegura una captura precisa de las variaciones del tono.

Por otro lado, al momento de obtener las marcas de pitch (puntos máximos locales dentro de cada ciclo fundamental) se presentó una dificultad inesperada: el algoritmo

de detección de frecuencia fundamental puede arrojar marcas erróneas en zonas donde la señal es ruido, aire o es prácticamente nula. Para solucionar esto, no solo se utilizó un rango de búsqueda acotado entre 80 Hz y 300 Hz, sino que también se predefinieron e introdujeron manualmente los intervalos periódicos de la señal correspondientes a las vocales y sonidos sonoros estables. De esta forma, el algoritmo ignora los tramos insonoros y calcula las marcas de pitch únicamente donde la periodicidad glotal es clara y relevante. Además de esto se graficaron los pitch marks, la señal modificada y la señal original a continuación:




Figura 31: Pitch marks detectadas.




Figura 32: Transformada de Fourier de la señal original y modificada.




Figura 33: Señal original de audio y modificada.

En la Figura 31 podemos apreciar los puntos rojos en los intervalos de las partes armónicas que fueron seleccionadas en el algoritmo, con esto verificamos que se localizaron con éxito los intervalos correspondientes. Por otro lado, en la Figura 32 se observa una comparación entre las transformadas de Fourier de las señales. Es claro que las señales fueron modificadas; se puede apreciar que hubo un corrimiento de la señal hacia la izquierda, lo cual coincide con la multiplicación de las frecuencias por el factor de 0,7, que disminuye las originales. Por último, en la Figura 33 podemos observar el cambio de la señal original de audio con la señal modificada, donde como ya se mencionó, las partes modificadas fueron únicamente las periódicas, mientras que las partes no periódicas están igual que en el audio original.